

Enrutamiento óptimo para el envío de pedidos compartidos basado en aprendizaje por refuerzo

Brando Miguel Palacios Mogollon

bpalaciosm@uni.pe



FACULTAD DE
CIENCIAS

Universidad Nacional de Ingeniería
Escuela Profesional de Ciencias de la Computación

Asesor: César Jesús Lara Avila

January 12, 2022

1. Introducción
2. Estado del Arte
3. Metodología del desarrollo
4. Resultados
5. Conclusiones y Trabajos futuros

1. Introducción
2. Estado del Arte
3. Metodologia del desarrollo
4. Resultados
5. Conclusiones y Trabajos futuros

La forma en la que nos movilizamos esta cambiando, el transporte privado como servicio ha sido el mas emergente en estos tiempos, por su servicio exclusivo. En esta investigación tomamos en cuenta uno de los servicios privados, el servicio de viajes compartidos (ridesharing), que permite a los viajeros compartir vehiculos con aquellos que tienen orígenes, destinos y horarios similares con poca antelación.

En este contexto se describe la pregunta que motiva la presente investigación: **¿Cómo podemos disminuir el kilometraje de los vehiculos que realizan transporte privado y beneficiar a los pasajeros con un algoritmo de inteligencia artificial?**. Para este fin, se propone desarrollar un modelo de aprendizaje por refuerzo profundo que permita reconocer en una lista de pedidos pendientes cual era la mejor ruta posible.

- ▶ Formular los parámetros del entorno estudiado que afectan la arquitectura propuesta.
- ▶ Identificar los beneficios que presenta un servicio ridesharing para la optimización de entrega de pedidos.
- ▶ Cotejar con otros modelos de enrutamiento de automóviles.
- ▶ Plantear un prototipo del modelo básico no escalable.

1. Introducción
2. Estado del Arte
3. Metodologia del desarrollo
4. Resultados
5. Conclusiones y Trabajos futuros

- ▶ Aprendizaje por refuerzo
 - MDP (Procesos de Decisión de Markov)
 - Exploración vs Explotación
 - Ecuación de Bellman
 - SARSA
 - Q-Learning
 - Q-Learning con Redes neuronales
 - ▶ Deep Q-Network (DQN)
- ▶ Viajes Compartidos
 - Patrones de viajes

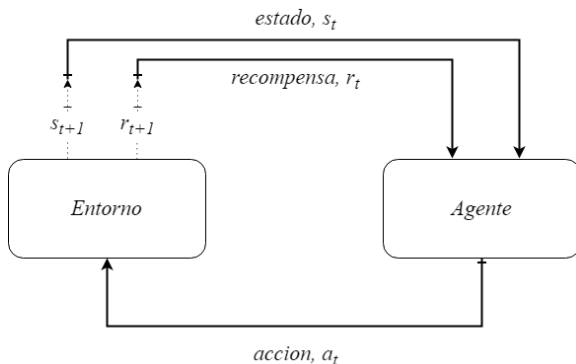


Figure 1: Ilustración de la interacción entorno-agente

(Fuente: Elaboración propia)

► Q learning

$$Q(s, a) \leftarrow Q(s, a) + \alpha(r + \gamma \max_{a'} Q(s', a') - Q(s, a))$$

Figure 2: Ecuación de actualización del valor Q

► Deep Q Learning

$$\mathcal{L}(\theta) = \mathbb{E}[(r + \gamma \max_{a'} Q(s', a'; \theta') - Q(s, a; \theta))^2]$$

Figure 3: Funcion de perdida para entrenar un algoritmo DQN

► Deep Q Learning




Figure 4: Modelo propuesto para la resolución de juegos de Atari

(Fuente: Mnih, Kavukcuoglu, and Silver [1])

► Patrones de viajes: Elementos posicionales

- **Real distance** dR_b : Nos referimos a la distancia original del viaje tomado si hubiera un solo pasajero, para el pasajero b .
- **Relative distance** d_b : Nos referimos a la distancia relativa del viaje tomado por el pasajero b no necesariamente solo.
- **Rideshare route** $R(a, B)$: Ruta de viaje compartido. Donde a es el conductor de la ruta y B es el conjunto de pasajeros del viaje.
- **Pick-up location** pk_b : Punto de recojo de un pasajero b .
- **Drop-off location** dp_b : Punto de despacho de un pasajero b .

- ▶ Se toma un modelo de carros vacíos en una cola de estados, que predice el flujo de automóviles en horarios del día. (Braverman, Dai, Liu, *et al.* [2])
- ▶ Generación de rutas influenciadas por un factor de recompensa y calculado por un DQN. (Haliem, Mani, Aggarwal, *et al.* [3])
- ▶ Algoritmo de SARSA distribuido que usa diferentes parámetros y asigna carros a clientes libres. (Rahili, Riviere, Olivier, *et al.* [4])
- ▶ Búsqueda de rutas usando un agente basado en ensayo y error para limitar rutas. (Khan and Lapkin [5])
- ▶ Toma de decisión de un DRL para el problema de enrutamiento dependiente de un grafo usando GNN y RL. (Almasan, Suárez-Varela, Badia-Sampera, *et al.* [6])

1. Introducción
2. Estado del Arte
3. Metodología del desarrollo
4. Resultados
5. Conclusiones y Trabajos futuros

Chicago Taxi Trips

Conjunto de datos recopilados desde el 2013 hasta el día de hoy, con reportes de viajes taxis en la ciudad de Chicago.

El conjunto de datos poseía 25 atributos que representaban el viaje.

Boundaries Community Areas

Conjunto de datos de estudio es una lista los bordes actuales del área comunitaria de Chicago. Estos están representados por 77 sub áreas, las cuales representan un sector del mapa de Chicago,

El conjunto de datos poseía 10 atributos que representaban cada área.




Figure 5: Ilustración del patron de viaje, viaje por desvio, $(pk_b, dp_b \in R(a, c))$

(Fuente: Elaboración propia)

► Selección de atributos:

- **Chicago Taxi Trips:** 5,837,917 datos y 11 atributos.
(Datos recopilados de enero 2019 a noviembre del 2021)
- **Boundaries Community Areas:** 77 datos y 5 atributos

► Separación de puntos:

Separación de puntos de recojo y puntos de entrega en tablas diferentes.

► Carga de datos:

Uso de base de datos espacial PostgreSQL (PostGIS).

- `commun_area`
- `dropoff_points`
- `pickup_points`

Para el problema de puntos y distancias se represento por un grafo dirigido, que mediante su matriz de adyacencia nos da lo siguiente:

$$\begin{pmatrix} 0 & d_1 & e_{12} & f_{12} & e_{13} & f_{13} \\ d_1 & 0 & f_{21} & l_{12} & f_{31} & l_{13} \\ e_{12} & f_{21} & 0 & d_2 & e_{23} & f_{23} \\ f_{12} & l_{12} & d_2 & 0 & f_{32} & l_{23} \\ e_{13} & f_{31} & e_{23} & f_{32} & 0 & d_3 \\ f_{13} & l_{13} & f_{23} & l_{23} & d_3 & 0 \end{pmatrix}$$

Donde:

- ▶ d_i : Representa las distancias de los puntos de recojo a sus destinos originales.
- ▶ e_{ij} : Representa las distancias entre el punto de recojo i al punto de recojo j , donde $i \neq j$.
- ▶ f_{ij} : Representa las distancias entre el punto de recojo i al punto de destino j , donde $i \neq j$.
- ▶ l_{ij} : Representa las distancias entre el punto de destino i al punto de destino j , donde $i \neq j$.




Figure 6: Grafo de 3 pedidos

(Fuente: Elaboración propia)

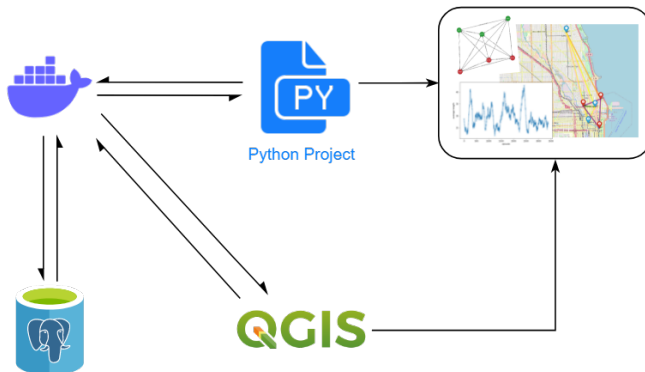


Figure 7: Ilustración del flujo de conexión del proyecto

(Fuente: Elaboración propia)

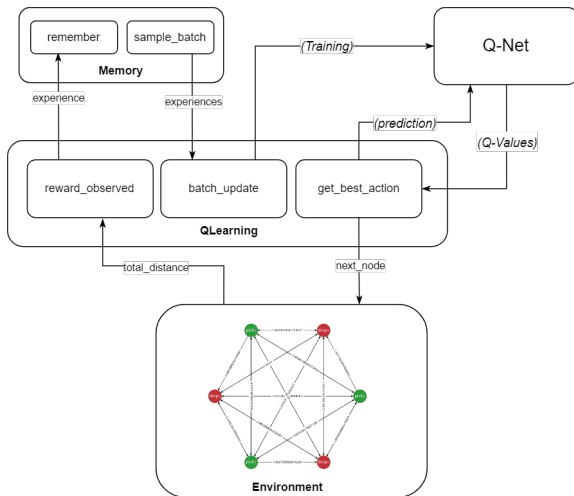


Figure 8: Ilustración de la estructura del modelo

(Fuente: Elaboración propia)




Figure 9: Ilustración de la estructura del modelo Q-Net

(Fuente: Elaboración propia)

Hiperparámetro	Descripción
minibatch	Número de épocas sobre los que se calcula cada actualización de Adam.
N_STEP_QL	Numero de pasos (n) de espera antes de calcular la estimación de recompensa objetivo.
nodes	Numero de nodos del grafo.
ϵ	Valor de exploración.
ϵ_{dr}	Factor de disminución de la valor de exploración.
α	Tasa de aprendizaje.
α_{dr}	Factor de disminución de la tasa de aprendizaje.
γ	Factor de descuento de recompensas.

Table 1: Hiperparámetros mas importantes de la arquitectura

1. Introducción
2. Estado del Arte
3. Metodología del desarrollo
- 4. Resultados**
5. Conclusiones y Trabajos futuros

- ▶ Se considero el promedio de distancia, entre el valor secuencial y el la distancia predecida el cual llamamos **average leagth**.
- ▶ La función de costo, MSELoss donde se efectuó el descenso de gradiente.




Figure 10: Gráfica de average leagth vs época de prueba

(Fuente: Elaboración propia)






Figure 11: Gráfica de resultado del costo vs época

(Fuente: Elaboración propia)



(a) Solución generada por el modelo
 $d = 22.36673$



(b) Solución secuencial
 $d = 40.13114$

Figure 12: Graficos generados por codigo.

(Fuente: Elaboración propia)

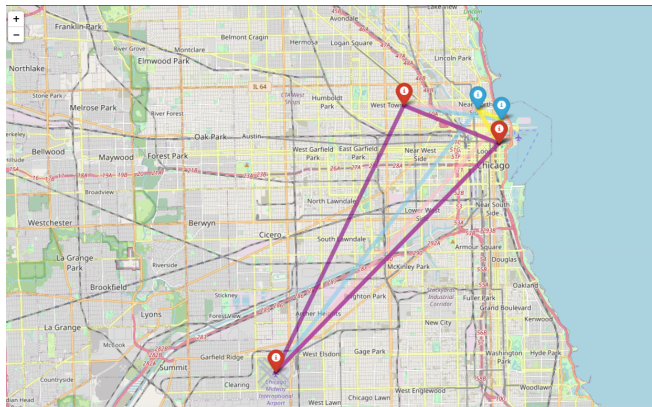


Figure 13: Ilustración de los nodos generados en QGIS

(Fuente: Elaboración propia)

1. Introducción
2. Estado del Arte
3. Metodología del desarrollo
4. Resultados
5. Conclusiones y Trabajos futuros

- ▶ Se diseñó una arquitectura que permite obtener solución al problema de enrutamiento para viajes compartidos usando los conceptos de aprendizaje por refuerzo y los patrones de viajes compartidos.
- ▶ Se formuló el grafo dirigido necesario que entienda el agente, mostrando resultados satisfactorios.
- ▶ La arquitectura mostró una disminución en las distancias recorridas por el modelo vs el flujo tradicional de viaje idéntico .
- ▶ Se pudo identificar los parámetros más comunes para enrutar viajes y los pesos necesarios para obtener la ruta ideal de viaje compartido.

- ▶ Se busca aumentar los parámetros de decisión en los pesos del grafo, además de incluir la posición del auto en el tiempo que es pedida la ruta.
- ▶ Implementar un modelo que pueda solucionar los 4 patrones de viajes compartidos.
- ▶ Realizar un modelo escalable que ofrezca resultados reales para la vida cotidiana.

- [1] V. Mnih, K. Kavukcuoglu, and D. Silver, “Human-level control through deep reinforcement learning,” *Nature*, vol. 518, pp. 529–533, 2015, ISSN: 0028-0836. DOI: <https://doi.org/10.1038/nature14236>.
- [2] A. Braverman, J. G. Dai, X. Liu, and L. Ying, “Empty-car routing in ridesharing systems,” *Oper. Res.*, vol. 67, pp. 1437–1452, 2019.
- [3] M. Haliem, G. Mani, V. Aggarwal, and B. Bhargava, “A distributed model-free ride-sharing approach for joint matching, pricing, and dispatching using deep reinforcement learning,” *IEEE Transactions on Intelligent Transportation Systems*, pp. 1–12, 2021. DOI: [10.1109/TITS.2021.3096537](https://doi.org/10.1109/TITS.2021.3096537).
- [4] S. Rahili, B. Riviere, S. Olivier, and S.-J. Chung, “Optimal routing for autonomous taxis using distributed reinforcement learning,” in *2018 IEEE International Conference on Data Mining Workshops (ICDMW)*, 2018, pp. 556–563. DOI: [10.1109/ICDMW.2018.00087](https://doi.org/10.1109/ICDMW.2018.00087).

- [5] A. Khan and A. Lapkin, "Searching for optimal process routes: A reinforcement learning approach," *Computers and Chemical Engineering*, vol. 141, p. 107 027, 2020, ISSN: 0098-1354. DOI: <https://doi.org/10.1016/j.compchemeng.2020.107027>. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0098135420303999>.
- [6] P. Almasan, J. Suárez-Varela, A. Badia-Sampera, K. Rusek, P. Barlet-Ros, and A. Cabellos-Aparicio, *Deep reinforcement learning meets graph neural networks: Exploring a routing optimization use case*, 2020. arXiv: [1910.07421](https://arxiv.org/abs/1910.07421) [cs.NI].