

Optimización de costos de viajes compartidos bajo demanda basados en aprendizaje por refuerzo

Brando Miguel Palacios Mogollon

bpalaciosm@uni.pe



FACULTAD DE
CIENCIAS

Universidad Nacional de Ingeniería
Escuela Profesional de Ciencias de la Computación

Asesor: César Jesús Lara Avila

January 24, 2023

1. Introducción
2. Estado del Arte
3. Metodología del desarrollo
4. Resultados
5. Conclusiones y Trabajos futuros

1. Introducción

2. Estado del Arte

3. Metodología del desarrollo

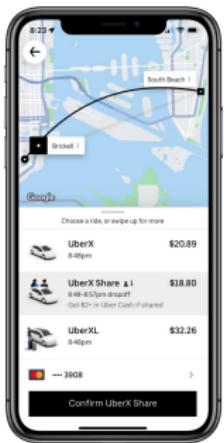
4. Resultados

5. Conclusiones y Trabajos futuros

El mundo ha pasado por algunos cambios tras la aparición de la pandemia mundial causada por el coronavirus SARS-COV2, alterando nuestra forma de elegir necesidades y intereses, entre ellas, la forma en que nos movilizamos.

Muchas empresas relacionadas al negocio de transporte urbano han modernizado sus servicios manteniendo su mercado de transportes privados, denominadas *empresas de redes de transporte* (Transportation Network Company, TNC)

Uber Technologies, Inc. es un ejemplo de un servicio TNC afectado por la pandemia, asiendo que realizaran reformas en sus servicios.



Uber

Figure 1: Ilustración del servicio *UberX Share*.

(Fuente: Uber Blog, 2022)

	TAXI POR APLICACIÓN	TAXI TRADICIONAL	METROPOLITANO	METRO DE LIMA	CORREDORES COMPLEMENTARIOS	BUSES, CUSTERS Y COMBIS
La rapidez	21.2%	27.1%	49.8%	63.8%	33.4%	20.4%
La seguridad	20.9%	6.2%	7.7%	5.5%	7.6%	4.1%
La puntualidad	16.6%	5.6%	9.2%	7.6%	8.7%	2.2%
La comodidad	12.3%	11.0%	5.6%	4.6%	10.3%	4.4%
El costo	12.0%	22.7%	5.5%	7.3%	11.4%	24.3%
El trato del personal	7.8%	9.4%	1.5%	2.1%	1.9%	4.1%
La limpieza	4.9%	7.2%	8.5%	4.7%	9.1%	2.8%
La cobertura de la ruta	1.6%	5.1%	7.9%	1.3%	5.1%	20.1%
El orden	0.9%	1.0%	1.7%	1.7%	6.9%	2.2%
No sabe	1.8%	4.6%	2.7%	1.4%	5.8%	15.5%

Figure 2: Tabla de valoración del servicio según el tipo de transporte.

(Fuente: Lima Cómo Vamos, 2022)

Principal forma para movilizarse antes y desde la pandemia

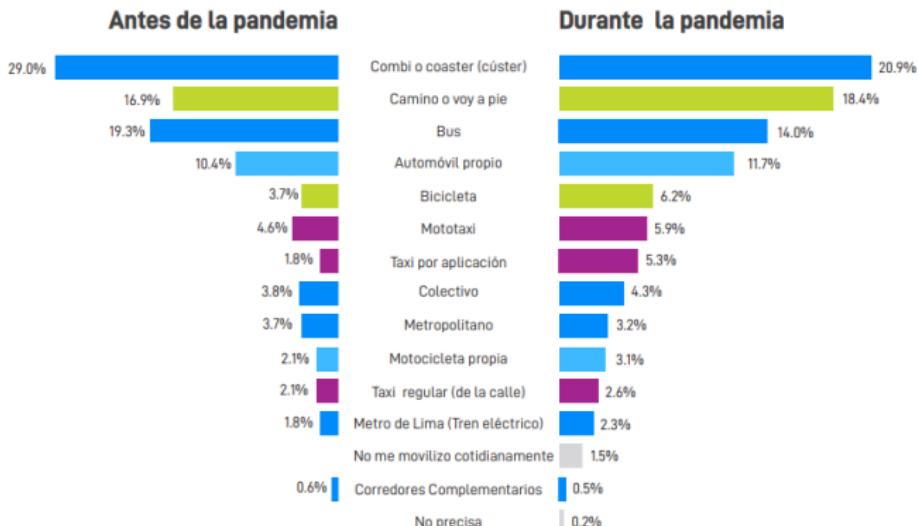


Figure 3: Gráfica comparativa antes y durante de la pandemia respecto a la forma de movilizarse.

(Fuente: Lima Cómo Vamos, 2021)

En los últimos años, indirectamente, hemos estado usando un tipo de viaje compartido en nuestra cotidianidad, usando alternativas que le hacen competencia al transporte público, entre ellos uso de los **taxis colectivos**.



Figure 4: Fotografia que representa a un taxi colectivo.

(Fuente: Grupo El Comercio, 2022)

En este contexto, se expone la pregunta que motiva la presente investigación:

¿Cómo podemos disminuir el kilometraje de los viajes a coches que realizan transporte privado y beneficiar a los pasajeros?

Objetivo general

Desarrollar una propuesta de optimización al problema de viajes compartidos aplicados para el cálculo de precios basado en las técnicas de aprendizaje por refuerzo profundo (DRL)

- ▶ Identificar la importancia de la optimización de precios en los servicios de transporte compartido.
- ▶ Formular algoritmo de solución basado en técnicas de inteligencia artificial con los parámetros del entorno estudiado que afectan la arquitectura propuesta.
- ▶ Diseñar una arquitectura de solución que permita minimizar los precios de viajes compartidos respecto a pedidos de viajes privados.
- ▶ Evaluar otras propuestas de solución adaptadas a los viajes compartidos.

1. Introducción

2. Estado del Arte

3. Metodología del desarrollo

4. Resultados

5. Conclusiones y Trabajos futuros

► Tipos de viajes compartidos

- **Static Ride-Sharing:** El numero de pasajeros y la ruta se conocen previamente. Se suele considerar como un servicio donde los pasajeros pueden tener orígenes comunes y diferentes puntos de despacho.
- **Dynamic Ride-Sharing:** No tiene conocimiento inicial de los pasajeros, su origen o destino. Toma los pedidos de forma que los vayan encontrando en su camino y con poca antelación.
- **Carpooling:** Son actividades menos flexibles donde se realizan viajes fijos donde existe un único destino y varias personas con un solo punto de partida.

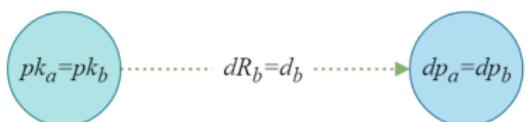
Tipo	Ventaja	Desventaja
Static Ride-Sharing	Óptimo para conjuntos pequeños	No escalable
Dynamic Ride-Sharing	No necesita información previa	Es codicioso y carga muchos casos
Carpooling	Ruta simple y libre de condiciones	Caso específico y poco flexible

Table 1: Tabla de ventajas y desventajas de los tipos de viajes compartidos.

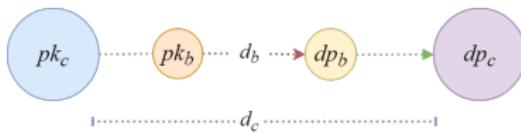
► Elementos posicionales

- **Real distance** dR_b : Nos referimos a la distancia original del viaje tomado si hubiera un solo pasajero, para el pasajero b .
- **Relative distance** d_b : Nos referimos a la distancia relativa del viaje tomado por el pasajero b no necesariamente solo.
- **Rideshare route** $R(a, B)$: Ruta de viaje compartido. Donde a es el conductor de la ruta y B es el conjunto de pasajeros del viaje.
- **Pick-up location** pk_b : Punto de recojo de un pasajero b .
- **Drop-off location** dp_b : Punto de despacho de un pasajero b .

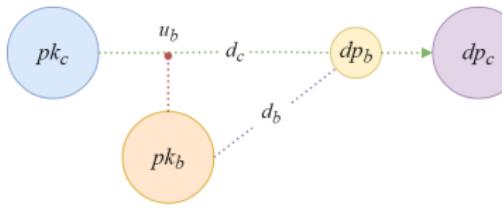
► Patrones de viaje



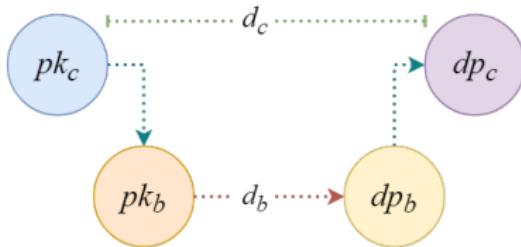
(a) Viaje Idéntico



(b) Viaje Incluido



(c) Viaje parcial



(d) Viaje por desvio

► Camino Hamiltoniano

Sea $G(V, E)$ un grafo con $|V| = n$, sin vértices aislados de aristas. Se denota un camino de Hamilton en G a todo camino que contiene los n vértices sin repetición.

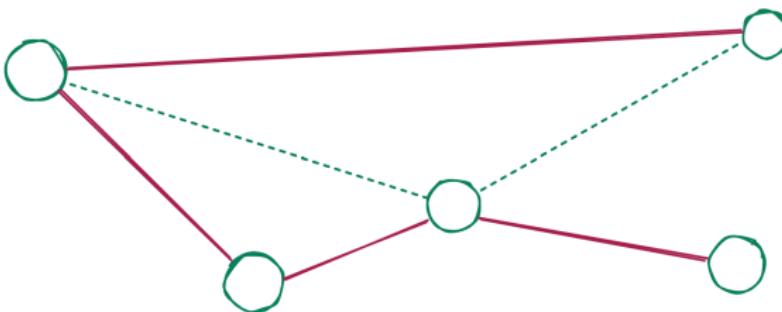


Figure 6: Ilustración de un camino Hamiltoniano generado

(Fuente: Elaboración propia)

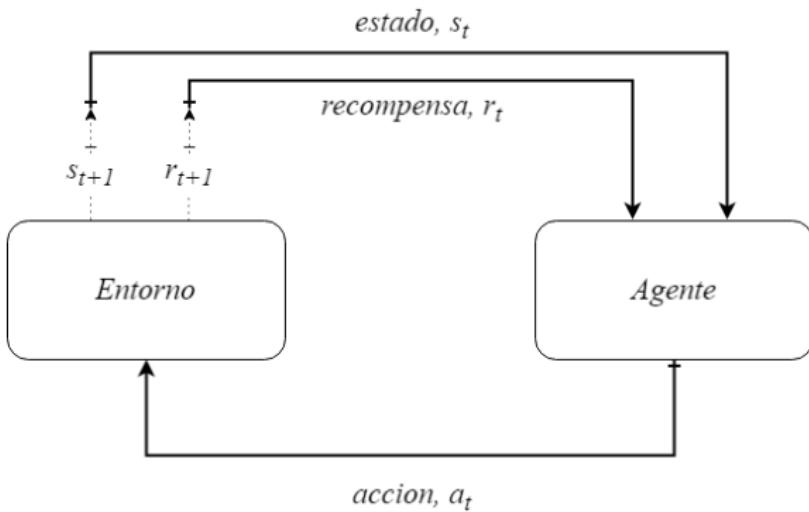


Figure 7: Ilustración de la interacción entorno-agente

(Fuente: Elaboración propia)

► Q learning

$$Q^*(s, a) \leftarrow Q(s, a) + \alpha(r(s, a) + \gamma \max_{a'} Q(s_{t+1}, a') - Q(s, a))$$

► Deep Q Learning

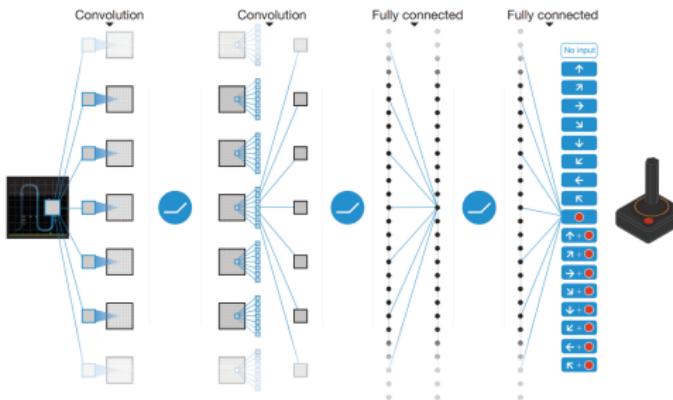


Figure 8: Ilustración de una red profunda (DQN) usada para el videojuego de ATARI.

(Fuente: Nature [1])

- ▶ **A distributed model-free ride-sharing approach for joint matching, pricing, and dispatching using DRL:** Modelo complejo de estimacion de precios influenciadas por un factor de recompensa y calculado por un DQN.[2]
- ▶ **DeepPool: Distributed model-free algorithm for ridesharing using DRL:** Uso de una DQN que, reconoce la demanda de viajes por zonas segun su frecuencia de pedidos en tiempo real. [3]
- ▶ **Algorithms for trip-vehicle assignment in ride-sharing:** Propuesta de asignación dinámica basada en un problema de optimización (VRP) mostrando que es NP-Hard. [4]

1. Introducción

2. Estado del Arte

3. Metodología del desarrollo

4. Resultados

5. Conclusiones y Trabajos futuros

Chicago Taxi Trips

Conjunto de datos relacionados al reporte de viajes en taxis de la ciudad de Chicago, recopilados desde el 2013 hasta el dia de hoy. El conjunto de datos poseia 25 atributos que representaban el viaje.

Boundaries Community Areas

Conjunto de datos geo-espaciales con los bordes actuales de cada área comunitaria de Chicago. Estos están representados por 77 sub áreas, las cuales representan un sector del mapa de Chicago. El conjunto de datos poseia 10 atributos que representaban cada área.

► Selección de atributos:

- **Chicago Taxi Trips:** 2,837,917 datos y 11 atributos.
(Datos recopilados de agosto 2022 a noviembre del 2022)
- **Boundaries Community Areas:** 77 datos y 5 atributos

► Observaciones:

- El conjunto de datos de Chicago Taxi Trips solo acepta viajes dentro de la misma ciudad.
- Ambos conjuntos de datos usan datos espaciales segun la especificación de *Simple Features for SQL* (SPSQL).

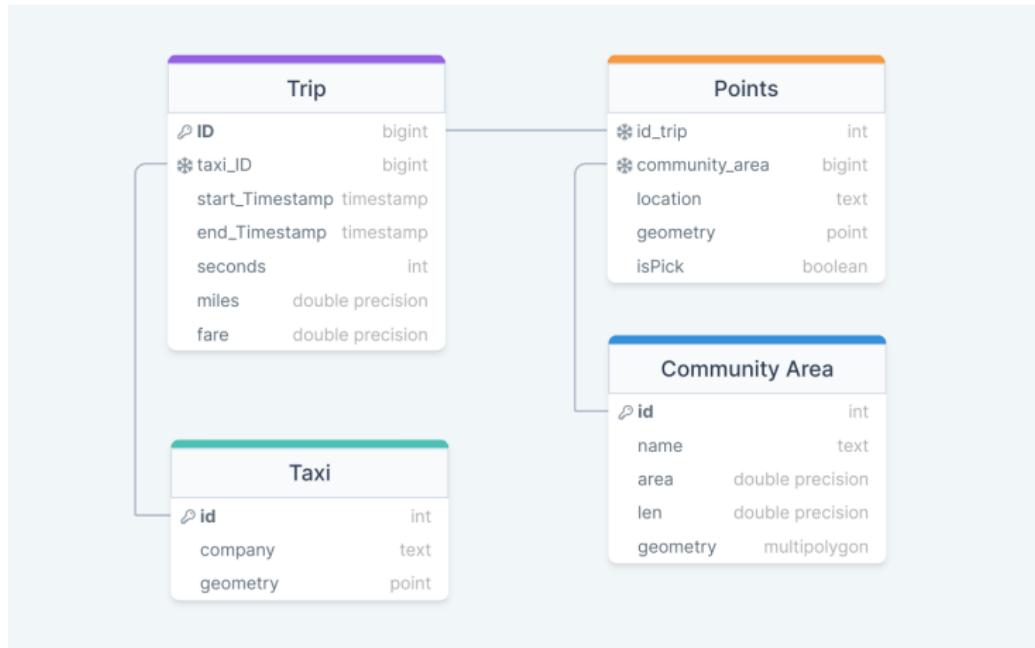
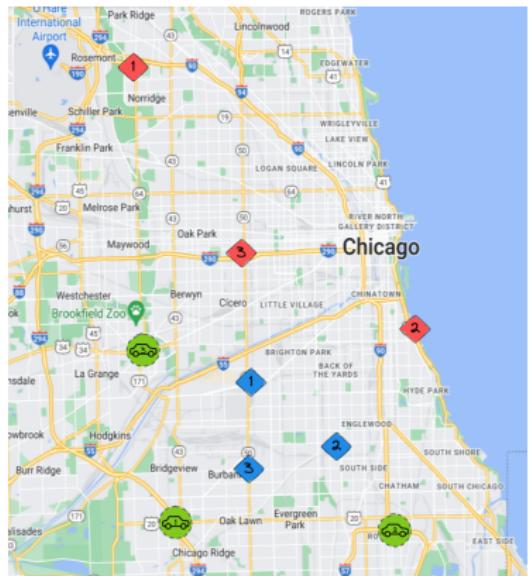


Figure 9: Modelo de Base de datos usando PostGIS

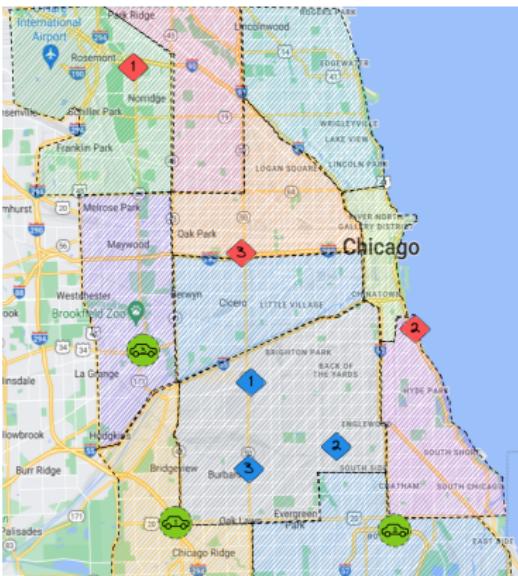
(Fuente: Elaboración propia)

Metodología del desarrollo

Planteamiento



(a) Puntos de 3 rutas

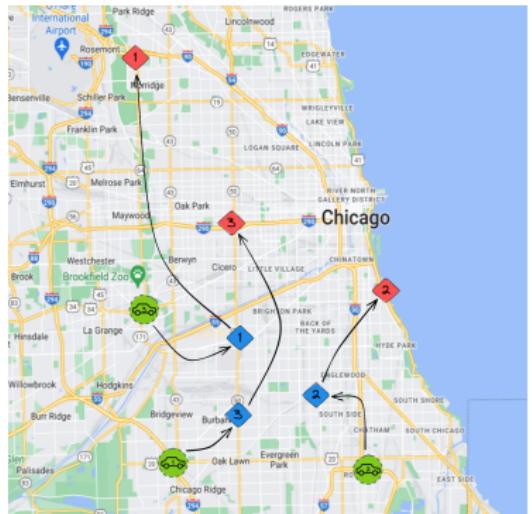


(b) Polígonos de áreas de Chicago

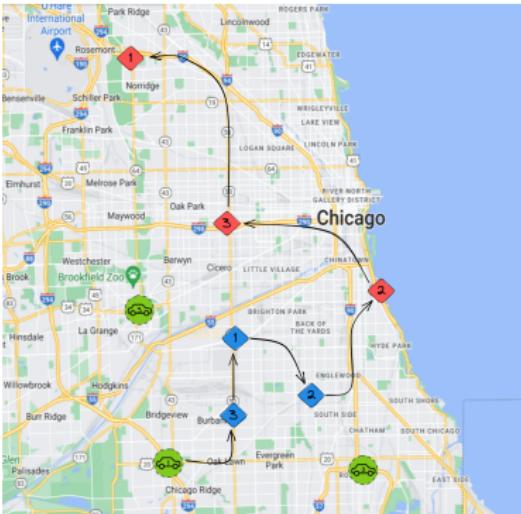
(Fuente: Elaboración propia)

Metodología del desarrollo

Planteamiento



(a) Viaje privado

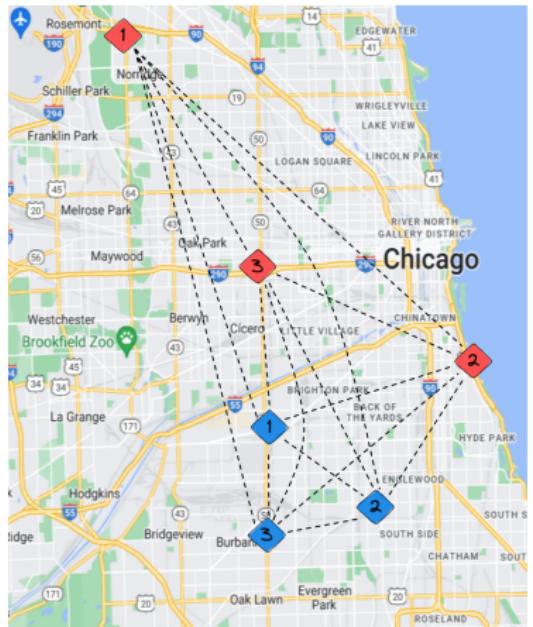


(b) Viaje compartido

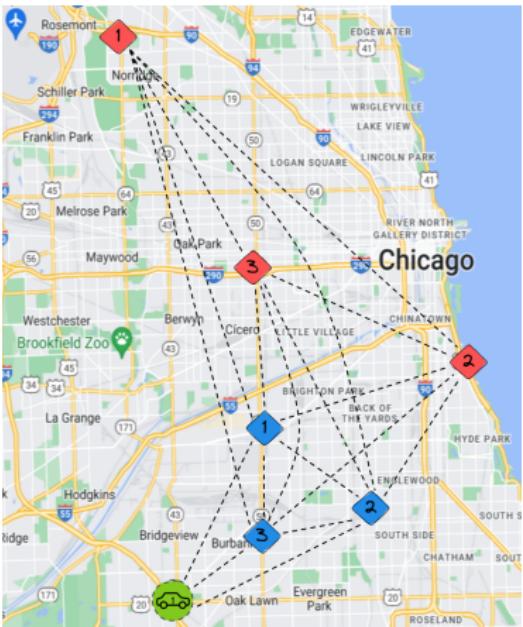
(Fuente: Elaboración propia)

Metodología del desarrollo

Planteamiento



(a) Red de recojo-destino.



(b) Red de recojo-destino extendido.

(Fuente: Elaboración propia)

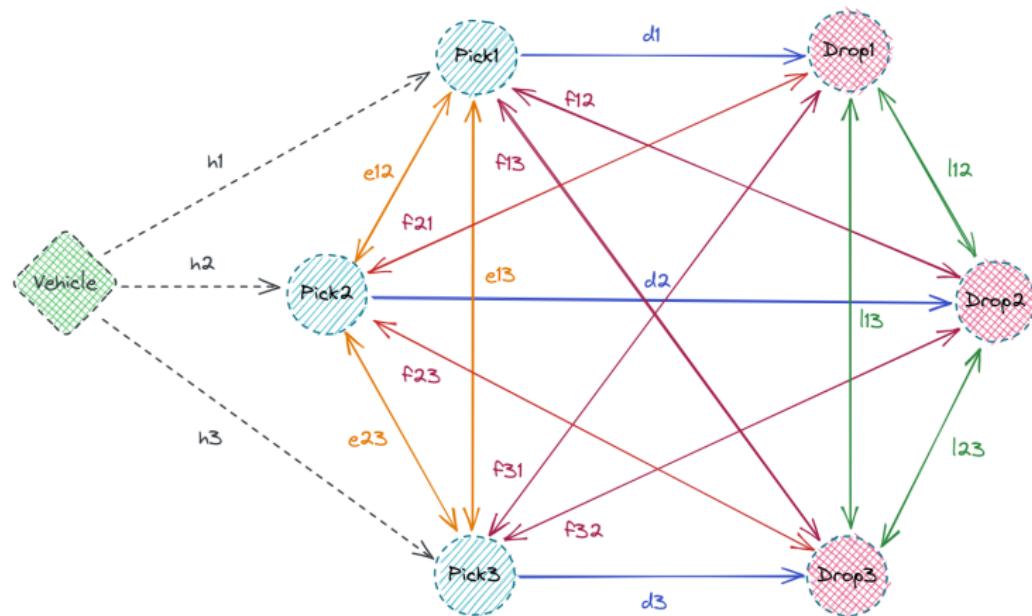


Figure 13: Grafo generado por los puntos del problema de viajes compartidos.

(Fuente: Elaboración propia)

Sea un digrafo ponderado $G = (V, E, \omega)$ vemos que:

$$V = \{v_i = (\text{Ing}, \text{lat})/v_i \in \mathbb{R}^2\}, \quad E \subseteq \{e = \overrightarrow{v_i v_f}/v_i, v_f \in V\}$$

Ademas, el conjunto de áreas comunitarias geográficas, *boundaires community areas* (BCA):

$$BCA = \{ \varepsilon = [p_0, \dots, p_n]/p_i, \overline{p_i p_{i+1}} \in \mathbb{R}^2, i \in [0, n] \}$$

Donde $\psi : E \rightarrow \mathbb{N}$ evalúa la cantidad de áreas que poseen una arista.

$$\psi(E(v_1, v_2)) = |E(v_1, v_2) \in BCA|$$

Finalmente usamos el conjunto Ω para definir la existencia de aristas dentro del conjunto de viajes compartidos, usando el conjunto de drivers D y pedidos R :

$$\Omega = \{ E(v_i, v_f) : v_f \notin d_j \vee i \neq f \vee (v_i, v_f \in r_k \wedge v_i \neq r_{k,drop}) \}$$

Generamos la función calificadora $w : E \rightarrow \mathbb{R}^+$:

$$w(v_1, v_2) = \begin{cases} E(v_1, v_2) \in \Omega & \sqrt{(v_{lat}^1 - v_{lat}^2)^2 + (v_{long}^1 - v_{long}^2)^2} \cdot (\psi(E(v_1, v_2))) \\ E(v_1, v_2) \notin \Omega & 0 \end{cases}$$

Se hace uso del grafo de la figura 13 para generar la matriz de adyacencia

$$Matrix_{ext}(G) = \begin{pmatrix} 0 & h_1 & 0 & h_2 & 0 & h_3 & 0 \\ h_1 & 0 & d_1 & e_{12} & f_{12} & e_{13} & f_{13} \\ 0 & d_1 & 0 & f_{21} & l_{12} & f_{31} & l_{13} \\ h_2 & e_{12} & f_{21} & 0 & d_2 & e_{23} & f_{23} \\ 0 & f_{12} & l_{12} & d_2 & 0 & f_{32} & l_{23} \\ h_3 & e_{13} & f_{31} & e_{23} & f_{32} & 0 & d_3 \\ 0 & f_{13} & l_{13} & f_{23} & l_{23} & d_3 & 0 \end{pmatrix}$$

Ponde la matriz de adyacencia de los pedidos de G es:

$$Matrix(G) = Matrix_{ext}(G)[1 :, 1 :] \quad (1)$$

► **Modelo Matemático**

Se uso una variante del problema VRP que permita resolver este problema usando un solver de programación entera (IP).

- **Variables de decisión:**

- ▶ X_{ij} : indica que el coche se mueve de un punto i a j (0 o 1).
- ▶ V_i : indica si el coche ya visito el punto i (0 o 1).

- **Función objetivo:**

$$\text{Min}(Z) = \sum_i \sum_j c_{ij} \cdot x_{ij} \quad (2)$$

Donde c_{ij} es el peso de la arista (i,j) .

► Modelo Matemático

- **Restricciones:**

- Todos los puntos deben ser visitados durante el recorrido:

$$\sum_i^n v_i = 1$$

- Los puntos de recojo solo pueden ser visitados una vez:

$$v_i \leq \sum x_{i,j} , \forall j$$

- Todo punto de entrega sólo puede ser visitado después de haber visitado su punto de recojo (i, j) :

$$v_j \leq v_i$$

- Solo se visitan los puntos de entrega que ya pasaron por su recojo, no necesariamente de forma consecutiva:

$$\sum_i \sum_j x_{ij} \leq v_i$$

$$\sum_i \sum_j v_i \geq x_{ij} + x_{ji}$$

► Algoritmo Genético

Algoritmo Genético	Instancia
Representación	$[e_3, e_1, \dots, e_n]$
Fitness	$\sum_i^{n-1} Edge(sol[i], sol[i + 1])$
Recombinación	Position Based Crossover - PBX
Mutación	Exchange Mutation - EM
Sel. Padres	Proportional
Sel. Sobrevivientes	Elitist
Población	90
p_c	0.63
p_m	0.26

► Aprendizaje por Refuerzo

- **Entorno:** Grafo objetivo representado de forma matricial.
- **Agente:** Red Neuronal Profunda de salidas Q-Values que use el valor promedio de las posibles acciones indicando la ventaja (Dueling DQN).

$$Q(s, a) = V(s) + (A(s, a) - \frac{1}{|\mathcal{A}|} \sum_{a'} A(s, a))$$

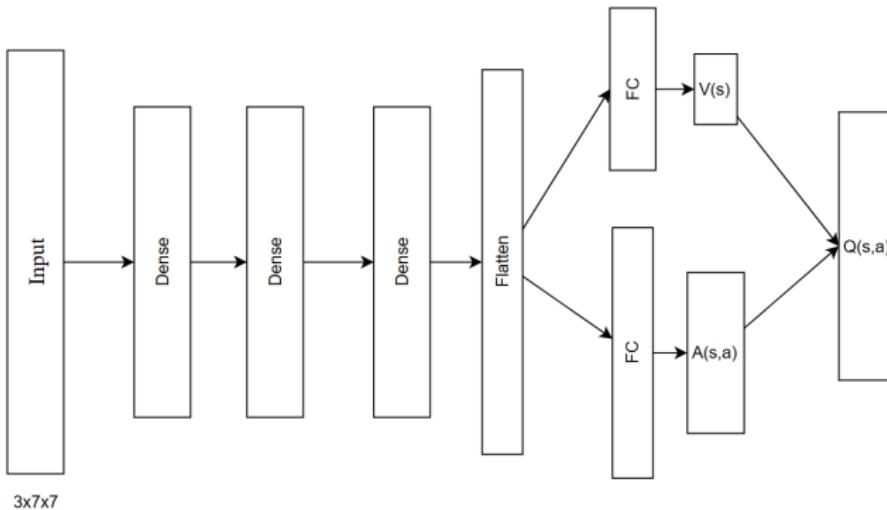


Figure 14: Ilustración de la estructura del modelo Dueling Q-Learning.

(Fuente: Elaboración propia)

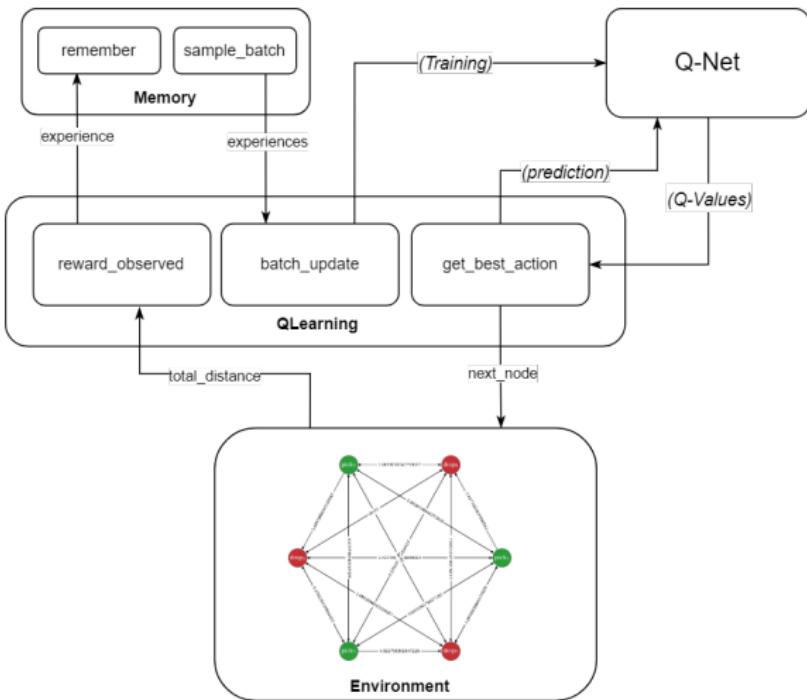


Figure 15: Ilustración de la estructura del modelo.

(Fuente: Elaboración propia)

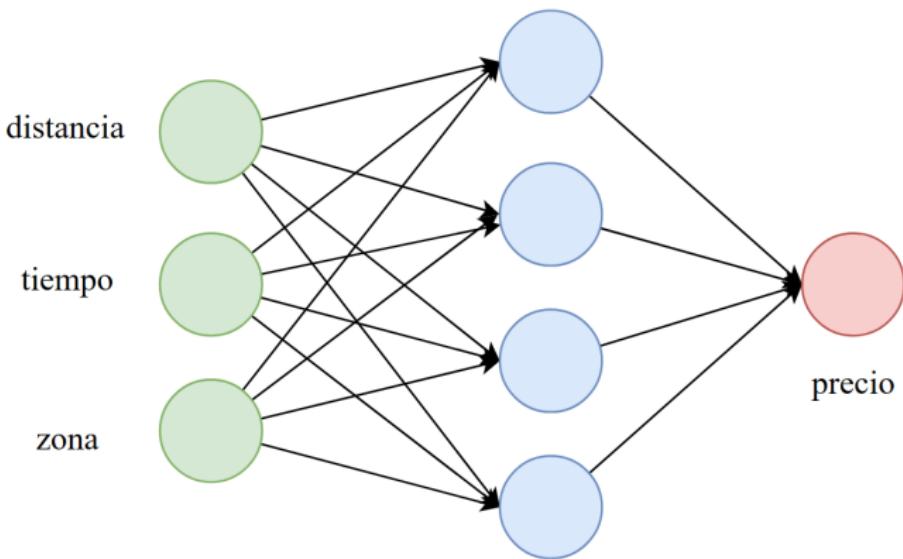


Figure 16: Ilustración de la estructura de la red neuronal que estima el precio.

(Fuente: Elaboración propia)

Flujo conceptual

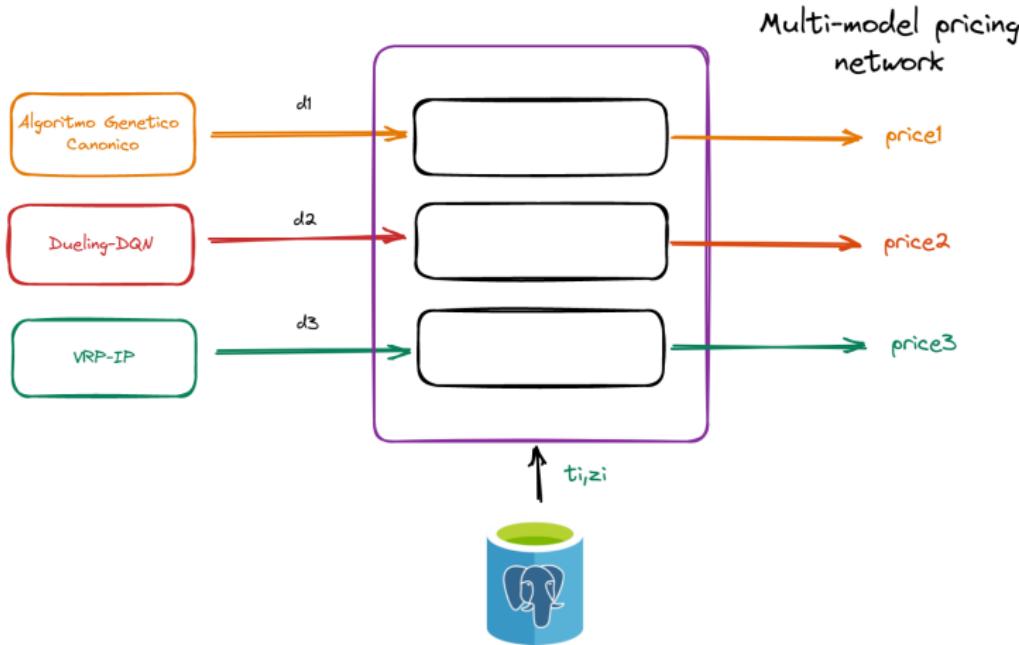


Figure 17: Ilustración del uso de la red de precios conectado a los modelos.

(Fuente: Elaboración propia)

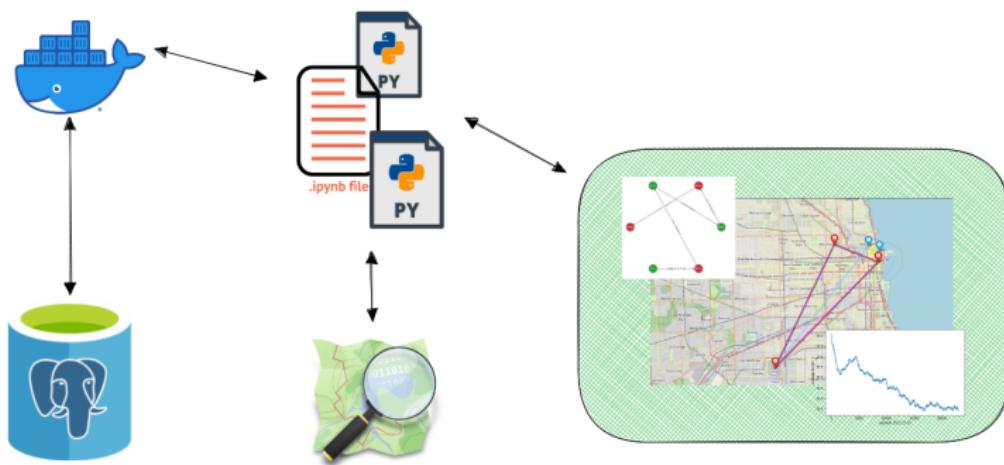


Figure 18: Ilustración del flujo de conexión del proyecto

(Fuente: Elaboración propia)

1. Introducción
2. Estado del Arte
3. Metodología del desarrollo
4. Resultados
5. Conclusiones y Trabajos futuros

Resultados

Aprendizaje de red de costo

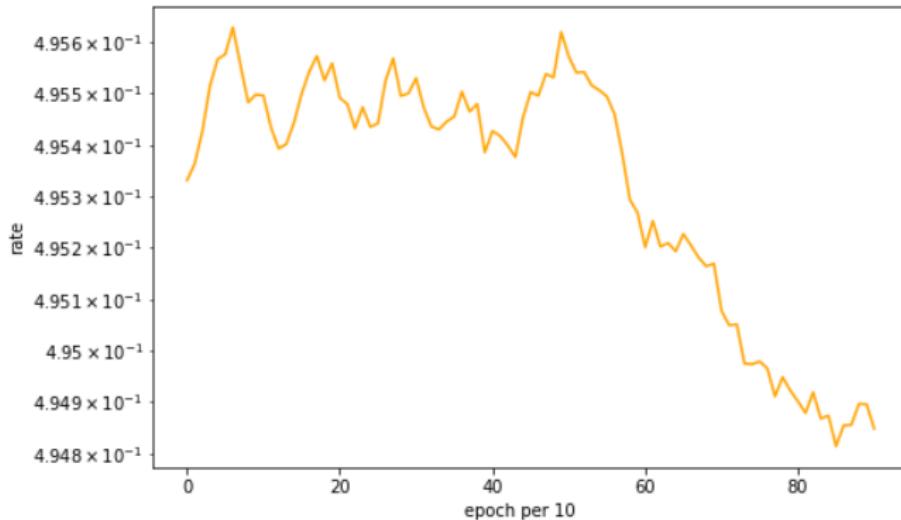


Figure 19: Gráfica de loss vs epoch por cada 10 iteraciones.

- ▶ **Métrica por varianza:** Cada modelo genera un precio distinto, usamos esto para determinar el sesgo que tienen, para eso fijamos el modelo IP.
- ▶ **Métrica por tiempo:** Tiempo de ejecución de cada modelo para tener un resultado óptimo.
- ▶ **Métrica por diversidad:** Uso de una muestra de datos distinta al original como validación de resolución de diferentes casos no esperados.

► Métrica por varianza

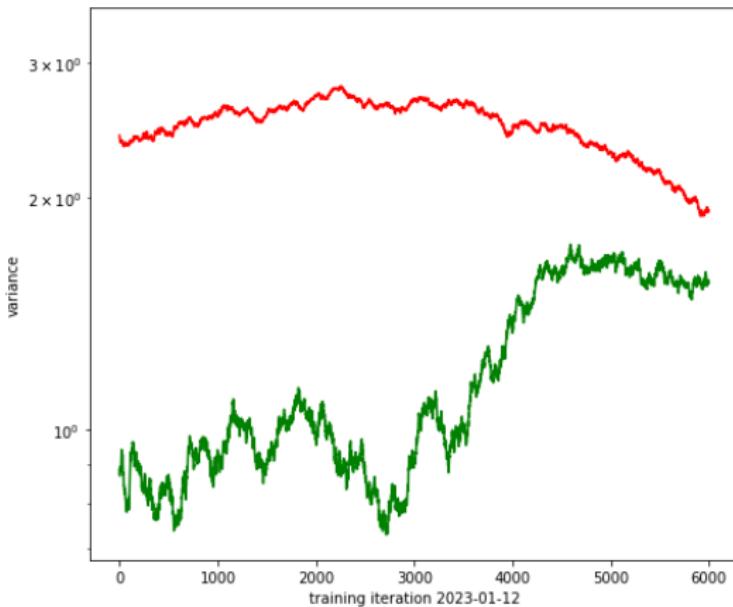


Figure 20: Gráfica comparativo entre la diferencia de precios. De rojo, Dueling-DQN vs variante VRP-IP y de verde, GA canonico vs el Dueling-DQ.

► Métrica por tiempos

Modelos	Tiempo de Convergencia	Tiempo de Entrenamiento	Tiempo de Ejecución
Dueling-DQN	~7.4min	~32.2min	~0.9min
Genetic Algortim	~10.2min	~22.3min	~0.3min
Variant VRP LP	~0min	~0min	~1.7min

Table 2: Comparación de tiempo de ejecución de cada modelo.

► Métrica por diversidad

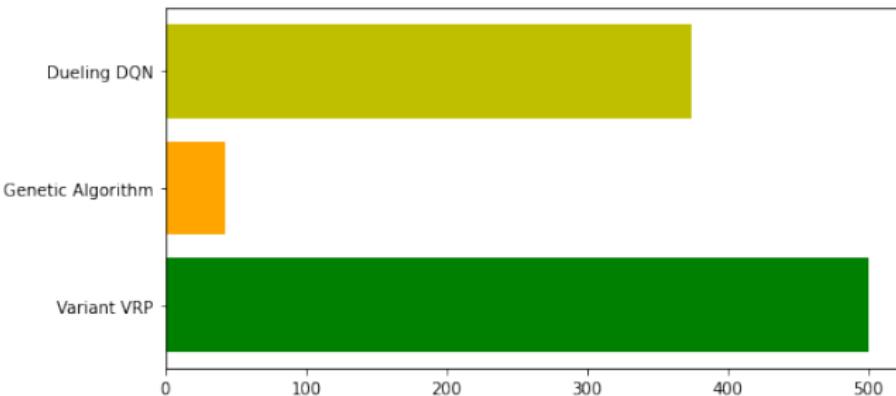


Figure 21: Barra comparativa de puebas post aprendizaje

(Fuente: Elaboración propia)

Resultados

Gráficos

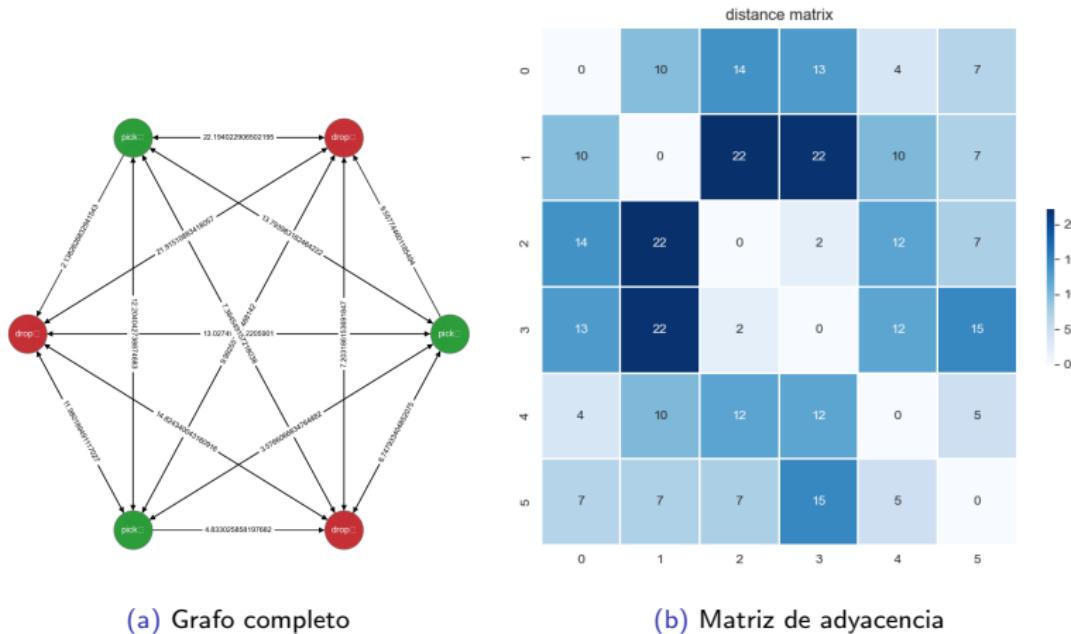
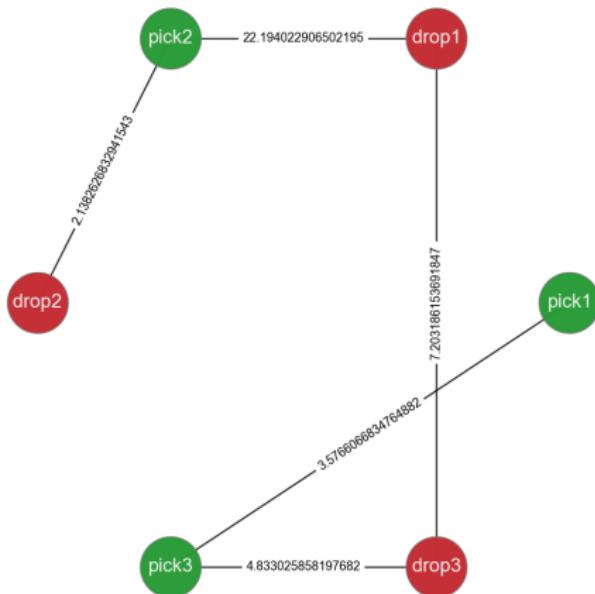


Figure 22: Graficas según representación de viaje compartido.

(Fuente: Elaboración propia)

Resultados

Gráficos



(a) Según el grafo resuelto

Figure 23: Graficas según representación en el mapa

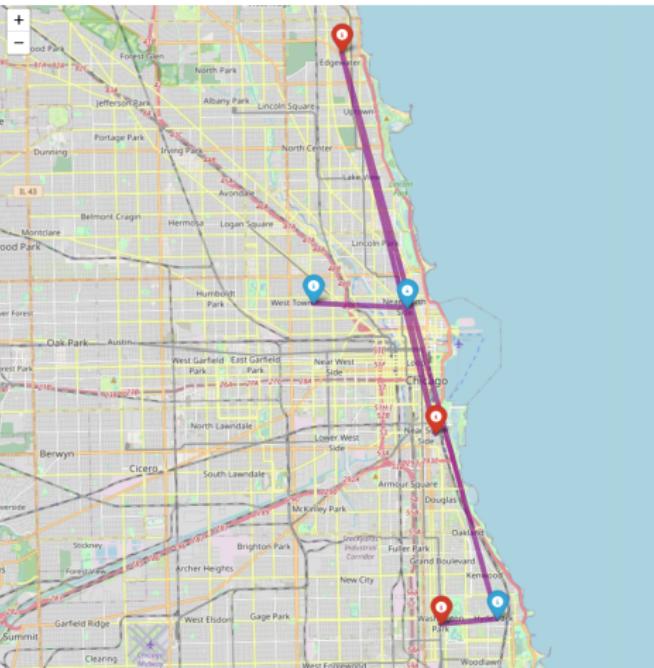
(Fuente: Elaboración propia)

Resultados

Gráficos



(a) Según la ruta (OSMX)



(b) Según el grafo (Folium)

Figure 24: Graficas según representación en el mapa

(Fuente: Elaboración propia)

1. Introducción
2. Estado del Arte
3. Metodología del desarrollo
4. Resultados
5. Conclusiones y Trabajos futuros

- ▶ Se diseño una arquitectura que permite obtener solución al problema de viajes compartidos usando los conceptos de aprendizaje por refuerzo y los patrones de viajes compartidos.
- ▶ Se formuló el grafo dirigido necesario que le permita a los diferentes modelos empleados en la investigación, sacarle el mejor provecho a la información presente en la base de datos de Chicago Taxi Trips.
- ▶ La arquitectura propuesta mostró la capacidad de adaptación de las redes neuronales conectadas a modelos completamente independientes, estimando precios ligeramente similares.
- ▶ Se pudo identificar y plantear los parámetros más comunes para resolver el problema de viajes compartidos y las condiciones para obtener su ruta ideal.

- ▶ El servicio de viaje compartido es un libro abierto a diferentes propuestas de implementación que permitan mejorar la calidad del servicio de taxis.
- ▶ El planteamiento del coche como agente individual nos ha ayudado a entender como realizar una ruta óptima; sin embargo, hace falta entender su comportamiento paralelo a varios agentes en el mismo entorno.

- [1] V. Mnih, K. Kavukcuoglu, and D. Silver, "Human-level control through deep reinforcement learning.", *Nature*, vol. 518, pp. 529–533, 2015, ISSN: 0028-0836. DOI: <https://doi.org/10.1038/nature14236>.
- [2] M. Haliem, G. Mani, V. Aggarwal, and B. Bhargava, "A distributed model-free ride-sharing approach for joint matching, pricing, and dispatching using deep reinforcement learning," *IEEE Transactions on Intelligent Transportation Systems*, pp. 1–12, 2021. DOI: [10.1109/TITS.2021.3096537](https://doi.org/10.1109/TITS.2021.3096537).
- [3] A. O. Al-Abbas, A. Ghosh, and V. Aggarwal, "Deeppool: Distributed model-free algorithm for ride-sharing using deep reinforcement learning," *IEEE Transactions on Intelligent Transportation Systems*, vol. 20, no. 12, pp. 4714–4727, 2019. DOI: [10.1109/tits.2019.2931830](https://doi.org/10.1109/tits.2019.2931830).

Bibliografia (cont.)

- [4] X. Bei and S. Zhang, "Algorithms for trip-vehicle assignment in ride-sharing," , vol. 32, Apr. 2018. DOI: [10.1609/aaai.v32i1.11298](https://doi.org/10.1609/aaai.v32i1.11298). [Online]. Available: <https://ojs.aaai.org/index.php/AAAI/article/view/11298>.